Self-Driving Cars

309611087 洪得瑜 2022 10/20

1 Part 1 Motion Dataset

Matplotlib 視覺化場景:

• 歷史軌跡: 綠色

• 未來軌跡: 紅色

• 道路中線: "--" 白色

• 道路邊線: 灰色

• 斑馬線: 紫色

• 周圍動態軌跡: 藍色




Figure 1: Dataset 場景圖

1.1 Code

```
plot_argo_scenario(sample):
fig = plt.figure()
          ax = fig.add_subplot(111)
          ax.set_facecolor('#2b2b2b')
          ''' History Trajectory '''
x = sample['x'].reshape(_OBS_STEPS, 6)
          ax.plot(x[:,0],
                   x[:,1],
                    color='g',
567
                    alpha=1,
568
569
                    linewidth=1
         ''' Future Trajectory '''
y = sample['y'].reshape(_PRED_STEPS, 5)
ax.plot(y[:,0],
571
572
573
574
               y[:,1],
"-",
               color='r',
576
577
               alpha=1,
               linewidth=1
578
580
          ''' Lane Centerline '''
         lane = sample['lane_graph'].reshape(-1, 10, 2)
for i in range(len(lane)):
[ax.plot(lane[i][:,0],
581
582
583
               lane[i][:,1],
585
               "--",
color='w',
586
587
               alpha=1,
linewidth=1
588
              ! )
neighbor_graph '''
          color='b',
                         alpha=1,
                          linewidth=1,
```

2 Part 2

Model Design: Model 中 Baseline 參考文獻 [1][2] 設計,建立高精地圖特徵 MapNet[1] 使用向量化地圖建構車道圖,而文獻 [1] 中以 LaneGCN 方法輸出地圖特徵,結合周遭動態特徵及車道特徵進行動態預測,而在本次車道與周圍關係以文獻 [2] VectorNet 方法將高經地圖特徵與車道及周圍動態融合, VectorNet 將同一元素以向量組成行成一條 poyline 將多個 polylines 行成 Subgraph,將所有軌跡和地圖特徵全局分析。

```
Input Layer
25 1
26 28 29 31 32 33 34 35 37 38 39 40 41 42 43 44 45 64 47 48 49 51 52 53
                                                                                                                            ((6 狀態 - 1 (obj)) * 5s 10Hz) = 250
              self.history_encoder = MLP(250, 128, 128)
              self.lane_encoder = MapNet(2, 128, 128, 10)
self.lane_attn = MultiheadAttention(128, 8)
                                                                                                                              道路空間位置和地圖建模 => 道路向量
              self.neighbor_encoder = MapNet(6,128,128, 11)
self.neighbor_attn = MultiheadAttention(128, 8)
                                                                                                                              周遭動態物體和地圖建模 => 動態物體向量
                  we predict 6 different future trajectories to handle different possible cases.
              for i in range(6):
    ''' future state (x, y, vx, vy, yaw) * 6s * 10Hz
                  trajs.append(
MLP(128, 256, 300)
                                                                                                                            Output Layer
                          use model to predict the confidence score of prediction
                                                                                                                             (5 \text{ state}(x, y, v_x, v_y, yaw)) * 6s * 10Hz = 300
                          nn.Sequential(
MLP(128, 64, 1),
nn.Sigmoid()
              self.future_decoder_traj = nn.ModuleList(trajs)
self.future_decoder_conf = nn.ModuleList(confs)
```




2.1 Case study

Argo Dataset: 以雨種方法調整解決路徑預測不佳問題

- 可增加 Epoch 次數可降低 train loss 而在 ADE(Average Displacement Error) 及 FDE(Final Displacement Error) 也可逐步降低。
- 而在加 Neighbor 的動態軌跡時有提高訓練收斂速度,可在較少 Epoch 達到最好的路徑。


2.1.1 直線預測

可成功預測出直線路徑,但 Epoch100 預測出直線有波浪現象因此多增加訓練次數效果較佳




2.1.2 變換車道

100Epoch 無法正確預測變換車道結果,但經由增加 Epoch 可成功預測出結果。




2.1.3 車輛轉彎預測

在 100epoch 及 1000epoch 都能預測出轉彎路徑, 但 1000epoch 效果較好



2.1.4 停止短路徑預測

由於歷史資料少或是停止所造成路徑預測效果不佳,提高 Epoch 能增加預測結果。




3 Kung Fu

經由 Argo 訓練好的模型套用到光復路資料集做測試,經過實驗測試結果顯示同樣的模型套用的效果跟 Argo Dataset 相比略有差距,對於直線預測可以正常預測,但變換車道可能預測並不是相當好,而在轉彎處及停止可正確預測出。


3.1 變換車道

Epoch100 無法預測出變換車道,而在 1000 epoch 已預測出切換車道但不完整可能需要在增加 Epoch 效果應該 能更好




3.2 車輛轉彎

相比之下 100 epoch 卻比起 1000 epoch 預測的更好,可得到並非訓練多次效果會越好。



3.3 車輛停止

車輛停止在 1000 epoch 有成功預測出,但 100epoch 未能預測出車輛停止



References

- [1] Liang, M., Yang, B., Hu, R., Chen, Y., Liao, R., Feng, S., Urtasun, R. (2020, August). Learning lane graph representations for motion forecasting. In European Conference on Computer Vision (pp. 541-556). Springer, Cham.
- [2] Gao, J., Sun, C., Zhao, H., Shen, Y., Anguelov, D., Li, C., Schmid, C. (2020). Vectornet: Encoding hd maps and agent dynamics from vectorized representation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 11525-11533).